

Phân loại tin tức tiếng Việt sử dụng PhoBERT

Trần Ngọc Hưng Nguyễn Hoàng Nam Khánh Trần Vũ Thành Luân

Khoa Công nghệ Thông tin
Trường Đại học Đà Lạt
Đà Lạt, Lâm Đồng, Việt Nam

Ngày 28 tháng 5 năm 2026

Nội dung trình bày

- 1 Giới thiệu
- 2 Mục tiêu
- 3 Cơ sở lý thuyết
- 4 Thu thập và xử lý dữ liệu
- 5 Huấn luyện mô hình
- 6 Kết quả
- 7 Ứng dụng demo
- 8 Kết luận

Động lực

- Sự bùng nổ của báo điện tử tiếng Việt
- Khối lượng tin tức khổng lồ được sản xuất hằng ngày
- Nhu cầu phân loại chủ đề tự động chính xác và bền vững

Ứng dụng

- Cá nhân hoá nội dung
- Gợi ý bài đọc
- Kiểm duyệt nội dung
- Phân tích xu hướng truyền thông

Thách thức với tiếng Việt

1 Ngôn ngữ đơn lập với từ ghép phổ biến

- Ví dụ: “công nghệ”, “giáo dục”
- Tách từ không chuẩn xác → sai lệch token

2 Hệ thống dấu thanh và dấu phụ phong phú

- Tokenizer đa ngữ thường mất thông tin
- Cần chuẩn hoá Unicode đúng

3 Bài báo dài (>1.000 token)

- Vượt giới hạn cửa sổ ngữ cảnh Transformer
- Cần kỹ thuật xử lý văn bản dài

Ba đóng góp chính

1 Công cụ thu thập dữ liệu

- Đa luồng, hỗ trợ 15 nguồn báo lớn
- Cơ chế checkpoint chống mất dữ liệu
- Dựa trên `newspaper3k` và `requests`

2 Pipeline xử lý dữ liệu

- Chuẩn hoá Unicode NFC
- Làm sạch HTML
- Khử trùng tiêu đề bằng n-gram ký tự

3 Mô hình phân loại

- Tinh chỉnh PhoBERT-base
- Kỹ thuật cửa sổ trượt cho văn bản dài
- Độ chính xác cao trên 11 chủ đề

PhoBERT và Transformer

PhoBERT

- Mô hình tiền huấn luyện cho tiếng Việt
- Dựa trên kiến trúc RoBERTa
- Huấn luyện trên 20GB văn bản tiếng Việt
- Vượt qua mBERT và XLM-R

Transformer

- Kiến trúc encoder-only
- Multi-head self-attention
- Position-wise FFN
- Layer normalization
- Positional encoding

Scaled Dot-Product Attention

Công thức

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$


Ví dụ: “Cầu thủ ghi bàn thắng”

- 1 **Tính điểm tương đồng:** Query “ghi” so với Key của tất cả từ
- 2 **Chuẩn hoá:** Chia cho $\sqrt{d_k}$ và áp dụng softmax
- 3 **Tổng hợp:** Tổng trọng số của Value vectors

Tại sao chia cho $\sqrt{d_k}$?

Ổn định gradient, tránh softmax bão hoà

Kỹ thuật Sliding Window



Tham số

- Kích thước cửa sổ: 256 tokens
- Bước nhảy: 128 tokens (overlap 50%)
- Tổng hợp: Average pooling các dự đoán

R-Drop

- Buộc dự đoán ổn định với các cấu hình dropout khác nhau
- Loss: $\mathcal{L} = \mathcal{L}_{\text{CE}} + \alpha \cdot \text{KL}(p_1 \| p_2)$
- $\alpha = 2.0$ trong thí nghiệm

Label Smoothing

- Tránh mô hình quá tự tin
- Cải thiện calibration
- $\epsilon = 0.05$ trong thí nghiệm

Công cụ thu thập dữ liệu

Nguồn dữ liệu

15 nguồn báo lớn: VnExpress, Tuổi Trẻ, Thanh Niên, Dân Trí, ...

Công cụ sử dụng

- `requests`: HTTP requests
- `BeautifulSoup4`: Parse HTML
- `lxml`: CSS selector
- `newspaper3k`: Trích xuất nội dung

Tính năng

- Đa luồng (song song hoá)
- Checkpoint (chống mất dữ liệu)
- Retry với exponential backoff

Pipeline xử lý dữ liệu

1 Chuẩn hoá Unicode NFC

- Thống nhất cách biểu diễn dấu thanh

2 Làm sạch HTML

- Loại bỏ thẻ HTML, script, style


3 Khử trùng tiêu đề

- N-gram ký tự ($n=3$)
- Jaccard similarity > 0.8

4 Lọc nhãn

- Loại bỏ các chủ đề có ít mẫu
- Giữ lại 11 chủ đề chính

Phân bố dữ liệu



Thống kê

- Tổng: 225.731 bài báo
- Train: 180.584 (80%)
- Test: 45.147 (20%)
- 11 chủ đề

Cấu hình huấn luyện


Phần cứng

GPU: NVIDIA RTX 4060 (16GB) | CPU: Ryzen 7 5800H | RAM: 16GB

Siêu tham số quan trọng

- Learning rate: 2×10^{-5} | Batch size: 32
- Warmup ratio: 0.06 | Weight decay: 0.01
- Label smoothing: 0.05 | R-Drop α : 2.0

Đường loss và accuracy



Phân tích quá trình huấn luyện (1)

Train loss giảm đều

- Mô hình đang học được đặc trưng phân biệt
- Tốc độ học và kỹ thuật ổn định hoạt động tốt

Eval loss tăng nhẹ ở cuối

- Dấu hiệu overfitting nhẹ
- Mức độ còn nhẹ nhờ regularization (R-Drop, label smoothing)

Phân tích quá trình huấn luyện (2)


Eval accuracy/F1 vẫn tăng dù eval loss tăng

Cross-entropy đo “độ tự tin”, accuracy đo quyết định cuối cùng


Kết luận:

- Mô hình học tốt và ổn định
- Overfitting nhẹ nhưng không ảnh hưởng đến hiệu suất
- Regularization hoạt động hiệu quả

Ma trận nhầm lẫn



Bảng kết quả benchmark




So sánh với baseline

Mô hình	Accuracy (%)	F1 Score
TF-IDF + SVM	82.45	0.8156
TF-IDF + Logistic Regression	81.23	0.8034
PhoBERT-base (ours)	90.10	0.9022

Cải thiện

- +7.65% accuracy so với TF-IDF + SVM
- +8.66 điểm F1 score



Tính năng

- Nhập văn bản tiếng Việt
- Dự đoán chủ đề với xác suất top-k
- Triển khai trên Streamlit

Đóng góp của nghiên cứu

Các đóng góp chính

- Công cụ thu thập dữ liệu đa luồng từ 15 nguồn báo
- Pipeline xử lý dữ liệu hoàn chỉnh
- Mô hình PhoBERT đạt 90.10% accuracy, $F1 = 0.9022$
- Ứng dụng demo trên Streamlit

Hướng phát triển

Các hướng nghiên cứu tiếp theo

- Mở rộng sang các chủ đề con chi tiết hơn
- Tích hợp phân tích cảm xúc
- Triển khai API cho hệ thống sản xuất
- Thử nghiệm với PhoBERT-large và các mô hình mới hơn

Cảm ơn các thầy cô và các bạn đã lắng nghe!

Câu hỏi và thảo luận